WUM - projekt nr 2 - raport

June 10, 2020

1 Ramka danych

Ramka danych zadana w zadaniu zawiera informacje nt. sesji na stronie sprzedażowej. Zawiera 10 zmiennych numerycznych i 8 kategorycznych. 'Revenue' to zmienna odnoszaca sie do tego, czy nastąpił zakup. "Administrative", "Administrative Duration", "Informational", "Informational Duration", "Product Related" i "Product Related Duration" reprezentują liczbę różnych rodzajów stron odwiedzanych przez odwiedzającego w tej sesji oraz całkowity czas spędzony w każda z tych kategorii stron. Kolumny "Bounce Rate", "Exit Rate" and "Page Value" reprezentuja dane mierzone przez "Google Analytics" dla każdej strony witryny e-commerce. Wartość funkcji "Bounce Rate" dla strony internetowej odnosi się do odsetka odwiedzających, którzy uzyskują dostęp do witryny z tej strony, a następnie wychodza ("odbijaja") bez wywoływania innych żądań do serwera analitycznego podczas tej sesji. Wartość kolumny "Exit Rate" dla określonej strony oblicza się tak, jak dla wszystkich odsłon strony, wartość procentowa, która była ostatnia sesja. Kolumna "Page Value" reprezentuje średnia wartość strony internetowej odwiedzanej przez użytkownika przed zakończeniem transakcji e-commerce. Funkcja "Dzień specjalny" wskazuje bliskość czasu wizyty w witrynie do określonego dnia specjalnego (np. Dzień Matki, Walentynki), kiedy sesje sa bardziej prawdopodobne, że transakcja zostanie sfinalizowana. Wartość tego atrybutu jest ustalana z uwzględnieniem dynamiki handlu elektronicznego, takiego jak czas trwania między datą zamówienia a data dostawy. Na przykład dla Walentynek ta wartość przyjmuje wartość niezerowa między 2 lutego a 12 lutego, zero przed tą datą i po tej dacie, chyba że zbliża się ona do innego specjalnego dnia i jej maksymalna wartość wynosi 1 8 lutego. Zestaw danych obejmuje również system użytkownika, przeglądarkę, region, typ ruchu, typ odwiedzającego jako powracającego lub nowego odwiedzającego, wartość logiczną wskazującą, czy data wizyty to weekend i miesiąc roku.

Chcemy znaleźć najbardziej naturalne podziały tego zbioru, które możnaby jakoś zinterpretować. Przy klasteryzacji usuwamy zmienną 'Revenue', ponieważ taki podział może być jednym z otrzymanych.

```
[2]: import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt

[3]: dataframe = pd.read_csv('online shoppers intention.csv')
```

```
[4]: dataframe
```

[4]:		Administrati	ve Adminis	trative_Dura	ation Info	rmational	\	
	0		0	_	0.0	0		
	1		0		0.0	0		
	2		0		0.0	0		
	3		0		0.0	0		
	4		0		0.0	0		
	4		O		0.0	U		
	 12325	•••	3		145.0	0		
				1				
	12326		0		0.0	0		
	12327		0		0.0	0		
	12328		4		75.0	0		
	12329		0		0.0	0		
		Informational Duration		ProductRelated ProductRelated_Duration \			\	
	0		0.0		1		0.00000	
	1		0.0		2	64	1.000000	
	2		0.0		1		0.00000	
	3		0.0		2		2.666667	
	4		0.0		10		7.500000	
				***	10		.000000	
	12325		0.0		53	1783	3.791667	
	12326		0.0		5		5.750000	
	12327		0.0		6		1.250000	
	12328		0.0		15		5.000000	
	12329		0.0		3		1.250000	
	12020		0.0		O	2.3	1.200000	
		BounceRates	ExitRates	PageValues	SpecialDa	_	peratingSy	stems \
	0	0.200000	0.200000	0.000000	0.0) Feb		1
	1	0.000000	0.100000	0.000000	0.0) Feb		2
	2	0.200000	0.200000	0.000000	0.0) Feb		4
	3	0.050000	0.140000	0.000000	0.0) Feb		3
	4	0.020000	0.050000	0.000000	0.0) Feb		3
	 1020E	 0 007149	 0. 000021	 10 0/1717			••	Л
	12325	0.007143	0.029031	12.241717				4
	12326	0.000000	0.021333	0.000000	0.0			3
	12327	0.083333	0.086667	0.000000	0.0			3
	12328	0.000000	0.021053	0.000000	0.0			2
	12329	0.000000	0.066667	0.000000	0.0) Nov		3
		Browser Reg	ion Traffi	сТуре	VisitorTy	oe Weekend	d Revenue	
	0	1	1	1 Retur	ning_Visit	or False	e False	
	1	2	1		ning_Visit		e False	
	2	1	9		ning_Visit			
	3	2	2		ning_Visit			
	4	3	1		ning_Visit			
	•••		•••			•••		
	12325	6	1	1 Retur	rning_Visit	or True	e False	

12326	2	1	8	Returning_Visitor	True	False
12327	2	1	13	Returning_Visitor	True	False
12328	2	3	11	Returning_Visitor	False	False
12329	2	1	2	${\tt New_Visitor}$	True	False

[12330 rows x 18 columns]

[5]: dataframe.describe()

[5]:		Administrative	Adminis	trative_	Duration	Information	onal '	\	
	count	12330.000000		1233	30.000000	12330.000	0000		
	mean	2.315166		8	30.818611	0.50	3569		
	std	3.321784		17	6.779107	1.27)156		
	min	0.00000		0.000000		0.000	0000		
	25%	0.000000			0.000000	0.000	0000		
	50%	1.000000			7.500000	0.000	0000		
	75%	4.000000		9	3.256250	0.000	0000		
	max	27.000000		339	98.750000	24.000	0000		
	Informational_Durational_count 12330.0000		uration	tion ProductRelated ProductRelated_Dura			uration	\	
			.000000	12330	0.00000		12330	.000000	
	mean	34	.472398	31	.731468		1194	.746220	
	std	140	0.749294 44.475503		.475503	1913.		.669288	
	min	0	.000000	C	0.00000	0		.000000	
	25%	0	.000000	7	7.000000 18		184	.137500	
	50%	0	.000000	18	3.000000		598	.936905	
	75%	0	.000000 38.000000		3.000000	1464.15721		.157213	
	max	2549	.375000	705	5.000000	63973.	.522230		
		BounceRates	ExitRa	+og - F	PageValues	s Special	l Dorr	\	
	count		2330.000		330.000000	-	•	\	
	mean	0.022191	0.043		5.889258				
	std	0.048488	0.043		18.568437				
	min	0.000000	0.000		0.000000				
	25%	0.000000	0.014		0.000000				
	50%	0.003112	0.025		0.000000				
	75%	0.016813	0.050		0.000000				
	max	0.200000	0.200		361.763742				
				-					
		OperatingSystems		s Browser Re		gion Tra	fficTy	pe	
	count	12330.00000	0 12330	.000000	12330.00	00000 12330	0.0000	00	
	mean	2.12400	6 2	.357097	3.14	7364	4.06958	86	
	std	0.91132	1.717277		2.40	2.401591 4.02516		69	
	min	1.00000	0 1	.000000	1.00	00000	1.0000	00	
	25%	2.00000	0 2	.000000	1.00	00000	2.0000	00	
	50% 2.000000		0 2	.000000	3.00	00000	2.0000	00	
	75%	3.00000	0 2	.000000	4.00	00000	4.0000	00	

max 8.000000 13.000000 9.000000 20.000000

Procent zakupów


```
[7]: dataframe.Revenue.mean()
```

[7]: 0.15474452554744525


2 Eksploracja danych

Administrative


```
[8]: sns.set(style="darkgrid")
     plt.figure(figsize=(15,15))
     plt.subplot(3, 2, 1)
     ax = sns.countplot(x='Administrative', data=dataframe)
     ax.set_xticklabels(ax.get_xticklabels(), rotation=45,_
     →horizontalalignment='right')
     plt.subplot(3, 2, 2)
     ax = sns.boxplot(x=dataframe['Administrative'])
     plt.subplot(3, 2, 3)
     ax = sns.countplot(x='Administrative', data=dataframe[dataframe['Revenue'] ==__
     →False])
     ax.set_xticklabels(ax.get_xticklabels(), rotation=45,_
     →horizontalalignment='right')
     plt.subplot(3, 2, 4)
     ax = sns.boxplot(x=dataframe[dataframe['Revenue'] == False]['Administrative'])
     plt.subplot(3, 2, 5)
     ax = sns.countplot(x='Administrative', data=dataframe[dataframe['Revenue'] ==__
     →Truel)
     ax.set_xticklabels(ax.get_xticklabels(), rotation=45,_
     →horizontalalignment='right')
     plt.subplot(3, 2, 6)
     ax = sns.boxplot(x=dataframe[dataframe['Revenue'] == True]['Administrative'])
     plt.show()
```



Informational



Product Related




Bounce, Exit, Page Rate


```
[11]: rates = ['BounceRates', 'ExitRates', 'PageValues']


sns.set(style="darkgrid")

fig = plt.figure(figsize=(12,8))
fig.subplots_adjust(hspace=0.4, wspace=0.4)
for i in range(1, 4):
    ax = fig.add_subplot(3, 1, i),
    ax = sns.boxplot(x=dataframe[rates[i-1]])
```



Systemy operacyjne i przeglądarki





3 Feature engineering

```
[13]: cleanup = {"Month": {"Jan": 1,
                            "Feb": 2,
                            "Mar": 3,
                            "Apr": 4,
                            "May": 5,
                            "June": 6,
                            "Jul": 7,
                            "Aug": 8,
                            "Sep": 9,
                            "Nov": 10,
                            "Oct": 11,
                            "Dec": 12},
                "VisitorType":{
                     "Returning_Visitor": 0,
                     "New_Visitor": 1,
                     "Other": 2
                }}
```

```
[14]: dataframe.replace(cleanup, inplace=True)
      dataframe.head()
[14]:
                          Administrative_Duration
         Administrative
                                                   Informational
                                               0.0
      0
                      0
                                                                 0
      1
                       0
                                               0.0
                                                                 0
      2
                       0
                                               0.0
                                                                 0
      3
                       0
                                               0.0
                                                                 0
                       0
                                               0.0
         Informational_Duration ProductRelated ProductRelated_Duration \
                             0.0
                                                                   0.000000
      0
                                                1
                             0.0
                                                2
      1
                                                                  64.000000
                             0.0
      2
                                                1
                                                                   0.000000
      3
                             0.0
                                                2
                                                                   2.666667
      4
                             0.0
                                               10
                                                                 627.500000
         BounceRates ExitRates
                                  PageValues SpecialDay Month OperatingSystems
                0.20
                            0.20
                                         0.0
                                                      0.0
                                                               2
      0
                                                                                  1
                                                      0.0
                                                               2
      1
                0.00
                            0.10
                                         0.0
                                                                                  2
                                                      0.0
      2
                0.20
                            0.20
                                         0.0
                                                               2
                                                                                  4
                0.05
                            0.14
                                                      0.0
                                                                2
                                                                                  3
      3
                                         0.0
                0.02
                            0.05
                                         0.0
                                                      0.0
                                                                2
                  Region TrafficType
                                        VisitorType Weekend
                                                               Revenue
      0
               1
                                                        False
                                                                  False
                        1
                                     1
                                                   0
               2
                                     2
      1
                        1
                                                   0
                                                        False
                                                                  False
                                                        False
                                                                  False
      2
               1
                        9
                                     3
                                                   0
               2
                                                        False
                                                                  False
      3
                                     4
                                                   0
               3
                        1
                                                         True
                                                                  False
[18]: import math
      date = list(dataframe.Month)
      date_sin = [math.sin(date[i]/12) for i in range (len(date))]
      date_cos = [math.cos(date[i]/12) for i in range (len(date))]
      dataframe['date_sin'] = date_sin
      dataframe['date_cos'] = date_cos
      dataframe = dataframe.drop('Month', axis=1)
```

Zaminiliśmy outliery, które mogły być spowodowane np. zostawieniem włączonego komputera.

Użyliśmy StandardScaler aby zestandaryzować dane.

```
[20]: from sklearn.preprocessing import StandardScaler

to_scale = ['Administrative_Duration', 'Informational_Duration',

'ProductRelated_Duration',

'BounceRates', 'ExitRates', 'PageValues', 'SpecialDay']

scaler = StandardScaler()

dataframe[to_scale] = scaler.fit_transform(dataframe[to_scale])
```

Parę prób wstępnego modelowania.

```
[21]: y = dataframe.Revenue
X = dataframe.drop('Revenue', axis=1)
```

```
[22]: X
```

[22]:	Administrative	Administrative_Duration	Informational	\
0	0	-0.614896	0	
1	0	-0.614896	0	
2	0	-0.614896	0	
3	0	-0.614896	0	
4	0	-0.614896	0	
•••	•••		•••	
123	325 3	0.673239	0	
123	326 0	-0.614896	0	
123	327 0	-0.614896	0	
123	328 4	0.051381	0	
123	329 0	-0.614896	0	

Informational_Duration ProductRelated ProductRelated_Duration \

```
0
                    -0.352755
                                            1
                                                             -0.829946
1
                                            2
                    -0.352755
                                                             -0.781368
2
                    -0.352755
                                            1
                                                             -0.829946
3
                                            2
                    -0.352755
                                                             -0.827922
4
                    -0.352755
                                           10
                                                             -0.353655
12325
                                           53
                                                              0.524004
                    -0.352755
                                            5
12326
                   -0.352755
                                                             -0.476428
12327
                                            6
                                                             -0.690095
                    -0.352755
12328
                                           15
                                                             -0.567322
                    -0.352755
12329
                    -0.352755
                                            3
                                                             -0.813817
      BounceRates ExitRates PageValues SpecialDay
                                                       OperatingSystems
0
          3.667189
                    3.229316
                                -0.317178
                                            -0.308821
                                                                      1
                                                                      2
1
        -0.457683
                    1.171473
                                -0.317178
                                            -0.308821
                                                                      4
          3.667189
                    3.229316
                                -0.317178
                                            -0.308821
3
                                                                      3
          0.573535
                     1.994610
                                -0.317178
                                            -0.308821
4
        -0.045196
                     0.142551
                                -0.317178
                                            -0.308821
                                                                      3
                                            -0.308821
12325
        -0.310366
                   -0.288966
                                0.342125
                                                                      4
                                -0.317178
                                            -0.308821
                                                                      3
12326
        -0.457683 -0.447364
          1.261014
12327
                                -0.317178
                                            -0.308821
                                                                      3
                   0.897093
12328
        -0.457683 -0.453140
                                -0.317178
                                            -0.308821
                                                                      2
12329
        -0.457683
                                -0.317178
                                            -0.308821
                                                                      3
                     0.485525
      Browser Region TrafficType VisitorType Weekend date_sin date_cos
0
                                                    False 0.165896
                                                                     0.986143
1
            2
                     1
                                  2
                                               0
                                                    False 0.165896 0.986143
2
            1
                     9
                                  3
                                               0
                                                    False 0.165896 0.986143
3
             2
                     2
                                  4
                                                    False 0.165896 0.986143
                                               0
4
             3
                                               0
                                                     True 0.165896 0.986143
                     1
                                  4
                                                     True 0.841471 0.540302
12325
            6
                     1
                                  1
                                               0
             2
12326
                     1
                                  8
                                               0
                                                     True 0.740177 0.672412
             2
12327
                     1
                                 13
                                               0
                                                     True 0.740177
                                                                     0.672412
12328
             2
                     3
                                 11
                                               0
                                                    False 0.740177 0.672412
12329
             2
                     1
                                  2
                                               1
                                                     True 0.740177 0.672412
```

[12330 rows x 18 columns]

```
[23]: from sklearn.metrics import accuracy_score
    from sklearn.cluster import KMeans

kmeans = KMeans(n_clusters=2, random_state=0).fit(X)
    pred = kmeans.labels_
    accuracy_score(y, pred)
```

[23]: 0.8125709651257097

```
[24]: from sklearn.cluster import AgglomerativeClustering

model = AgglomerativeClustering(n_clusters=2, linkage='single').fit(X)

pred = model.labels_
accuracy_score(y, pred)
```

[24]: 0.8450932684509327

```
[25]: from sklearn.cluster import AgglomerativeClustering

model = AgglomerativeClustering(n_clusters=2, linkage='ward').fit(X)

pred = model.labels_
accuracy_score(y, pred)
```

[25]: 0.22668288726682886

```
[26]: from sklearn.cluster import AgglomerativeClustering

model = AgglomerativeClustering(n_clusters=2, linkage='complete').fit(X)

pred = model.labels_
accuracy_score(y, pred)
```

[26]: 0.8451743714517437

```
[27]: from sklearn.cluster import AgglomerativeClustering

model = AgglomerativeClustering(n_clusters=2, linkage='average').fit(X)

pred = model.labels_
accuracy_score(y, pred)
```


[27]: 0.8450932684509327

Widzimy, że zakładając dwa klastry (kupujący/niekupujący) osiągamy całkiem dobre accuracy względem danego Revenue.

4 Checkpoint 3

4.1 Szukanie optymalnej ilości klastrów

4.1.1 Elbow method




Z metody łokcia moglibyśmy przyjąć k=3lub k=4

4.1.2 Metryki

```
[29]: from sklearn.metrics import silhouette_score, davies_bouldin_score,
       →calinski_harabasz_score
[30]: k_max = 10
      col = ["k","KMeans","Agglomerative_single","Agglomerative_ward",
             "Agglomerative_complete", "Agglomerative_average"]
      # silhouette score
      metric_silhouette = pd.DataFrame(columns=col)
      for i in range(2,k max+1):
          metric_silhouette = metric_silhouette.append(
              {"k" : i,}
               "KMeans" : silhouette_score(dataframe, KMeans(n_clusters=i).
       →fit predict(dataframe)),
               "Agglomerative_single" : silhouette_score(dataframe, __
       →AgglomerativeClustering(n_clusters=i,linkage='single').
       →fit_predict(dataframe)),
               "Agglomerative ward" : silhouette score(dataframe,
       →AgglomerativeClustering(n_clusters=i,linkage='ward').fit_predict(dataframe)),
               "Agglomerative_complete" : silhouette_score(dataframe, ___
       →AgglomerativeClustering(n_clusters=i,linkage='complete').
       →fit_predict(dataframe)),
               "Agglomerative_average" : silhouette_score(dataframe, __
       →AgglomerativeClustering(n_clusters=i,linkage='average').
       →fit_predict(dataframe)),},
              ignore_index=True)
      # davies_bouldin_score
      metric_davies_bouldin = pd.DataFrame(columns=col)
      for i in range(2,k_max+1):
          metric_davies_bouldin = metric_davies_bouldin.append(
              {"k" : i,}
               "KMeans" : davies_bouldin_score(dataframe, KMeans(n_clusters=i).
       →fit predict(dataframe)),
               "Agglomerative_single" : davies_bouldin_score(dataframe, __
       →AgglomerativeClustering(n_clusters=i,linkage='single').
       →fit_predict(dataframe)),
               "Agglomerative_ward" : davies_bouldin_score(dataframe, ___
       →AgglomerativeClustering(n_clusters=i,linkage='ward').fit_predict(dataframe)),
               "Agglomerative_complete" : davies_bouldin_score(dataframe, ___
       →AgglomerativeClustering(n_clusters=i,linkage='complete').
       →fit_predict(dataframe)),
               "Agglomerative average" : davies bouldin score(dataframe,
       →AgglomerativeClustering(n_clusters=i,linkage='average').
       →fit_predict(dataframe))},
              ignore_index=True)
```

```
# calinski_harabasz_score
metric_calinski_harabasz = pd.DataFrame(columns=col)
for i in range(2,k_max+1):
    metric_calinski_harabasz = metric_calinski_harabasz.append(
        {"k" : i,}
         "KMeans" : calinski_harabasz_score(dataframe, KMeans(n_clusters=i).
 →fit_predict(dataframe)),
         "Agglomerative_single" : calinski_harabasz_score(dataframe, ___
 →AgglomerativeClustering(n_clusters=i,linkage='single').
 →fit_predict(dataframe)),
         "Agglomerative ward" : calinski harabasz score(dataframe,
 →AgglomerativeClustering(n_clusters=i,linkage='ward').fit_predict(dataframe)),
         "Agglomerative_complete" : calinski_harabasz_score(dataframe,_
 →AgglomerativeClustering(n_clusters=i,linkage='complete').
 →fit_predict(dataframe)),
         "Agglomerative_average" : calinski_harabasz_score(dataframe, ___
 →AgglomerativeClustering(n_clusters=i,linkage='average').
 →fit_predict(dataframe))},
        ignore_index=True)
```



```
[35]: from sklearn import preprocessing
      s = metric_silhouette + preprocessing.normalize(metric_calinski_harabasz) +__
      →(1-metric_davies_bouldin)
      s['k'] = range(2,k max+1)
[35]:
                       Agglomerative_single Agglomerative_ward \
          k
               KMeans
      0
          2
            1.912789
                                   1.891746
                                                        1.941578
      1
          3
            1.860476
                                   1.827673
                                                        1.546723
      2
          4 1.733613
                                   1.882808
                                                        1.709538
      3
            1.660789
                                   1.758067
                                                        1.662114
      4
          6 1.574099
                                   1.654696
                                                        1.387984
      5
            1.510583
                                   1.482625
                                                        1.358106
      6
          8 1.471595
                                   1.504723
                                                        1.374624
      7
          9 1.412210
                                   1.561965
                                                        1.216033
      8 10 1.312532
                                   1.530294
                                                        1.200880
         Agglomerative_complete Agglomerative_average
      0
                       1.838765
                                              1.790877
                       1.565484
                                              1.689359
      1
      2
                       1.490530
                                              1.629409
      3
                       1.515554
                                              1.528185
      4
                       1.448359
                                              1.453973
      5
                       1.398537
                                              1.469827
      6
                       1.405135
                                              1.425363
      7
                       1.372040
                                              1.405992
                       1.405927
                                              1.355893
[36]: print("Clusters number: ",s.drop('k',axis=1).max(axis=1).idxmax()+2)
      print("Best algorithm : ",s.drop('k',axis=1).max(axis=0).idxmax())
     Clusters number: 2
     Best algorithm : Agglomerative_ward
[37]: model = AgglomerativeClustering(n_clusters=2, linkage='ward').
       →fit_predict(dataframe)
      accuracy_score(y, model)
```

[37]: 0.8253041362530413

Widzimy, że najlepszy algorytm podzielił zbiór na dwa klastry, tak jak podejrzewaliśmy.

Zauważmy, że jest to bardzo podobny podział do podziału oryginalnego na osoby, które kupiły i nie.